

Skill Spec Midtraining: 让模型在学会"怎么调"之前先懂"为什么调"

Research Proposal | 2026-06-12 | 配套文献调研见 [survey.html](#)

1. 摘要

现有 tool / skill SFT 主要教模型模仿"怎么调用工具", 缺少对"为什么需要该 skill、什么时候不用、相似 skill 如何区分、调用后如何验证结果"的显式学习。我们提出 Skill Spec Midtraining (SSM): 在 tool-use SFT 之前插入一个 midtraining 阶段, 用大规模合成语料让模型先学习每类 skill 的适用边界、选择理由、失败模式和使用原则 (统称 Skill Spec), 再做标准 tool SFT。本工作把 Anthropic 的 Model Spec Midtraining (MSM, 2026) —— "知其然更要知其所以然" 的训练思想 —— 从安全行为规范域扩展到 skill/tool 域。MSM 在安全域已实证: spec midtraining 使后续微调数据需求降 40–60×、OOD 误对齐率从 54–68% 降到 5–7%。我们假设同样的机制迁移到 skill 域, 将提升 skill selection (RQ1)、execution 质量 (RQ2)、数据效率 (RQ3) 与 OOD 泛化 (RQ4)。

2. 动机与立论

2.1 现状的三个定量痛点

- 不知道何时不用: LLM 超过 30% 的工具调用是不必要的 (SMART, arXiv: 2502.11435); BFCL Irrelevance Detection 上 Llama3-8B 仅 ~20%。
- 给了 spec 也不会用: 在 34k 真实 skill 库上, 推理时检索注入 skills 的收益脆弱、常接近无 skill 基线 (arXiv:2604.04323) —— 说明问题不在"缺信息"而在"缺内化"。
- SFT 学形不学神: 行为克隆式 tool SFT 对新工具/扰动描述脆弱 (近测试分布训练时 OOD 可跌 67%), 增强推理反而放大工具幻觉 (The Reasoning Trap, arXiv:2510.22977)。

2.2 为什么是 midtraining（而非 SFT 或 prompt）

- 机制：midtraining 做"分布桥接"、重塑表征，收益在离预训练分布最远的领域最大（arXiv:2510.14865）——tool 调用恰属此类；SFT 只能在已有表征上学格式映射。
- 知识抽取：陈述性知识必须在(中期)预训练经多样化改写注入才可被下游抽取，SFT 救不回来（Physics of LM 3.1, arXiv:2309.14316）；SFT 期注入新知识还会推高幻觉（arXiv:2405.05904）。
- 先例：MSM 实测 spec midtraining 优于 Deliberative Alignment 式 SFT 注入，且无 CoT 的后续微调即可超过有 CoT 的基线。

核心假设：skill 的"为什么/何时/边界/验证"是一种陈述性知识 + 推理模式，应在 midtraining 注入权重；SFT 阶段只负责把它接到调用行为上。学过 spec 的模型在未见过的工具、组合与领域上，会用 spec 推理模式补位，而不是死记工具-轨迹映射。

3. 方法

3.1 Skill Spec 的五要素定义

对每个 skill（粒度：API 单函数 → 函数族 → 复合 skill，如 SKILL.md），编写结构化规范：


S1 功能与适用边界（capability & scope）：能做什么、输入输出契约、不能做什么
S2 何时不用（when-NOT-to-use）：参数知识可答时不调用；前置条件不满足时澄清而非硬调；无合适工具时明确拒绝
S3 相似 skill 区分（contrastive disambiguation）：与近邻 skill 的成对对比——什么时候用 A 不用 B，给判据不给死规则
S4 失败模式（failure modes）：典型错误（参数幻觉、错误嵌套、状态依赖违反）+ 判例库（真实失败案例 + 归因分析，借鉴 Case-Augmented DA, arXiv: 2601.08000）
S5 调用后验证原则（post-call verification）：返回值的合理性检查、何时重试 / 换工具 / 上报失败

S2/S3/S5 是文献中最空白的三个要素（见 survey § 4、§ 7.3）。

3.2 数据合成 pipeline（仿 MSM 配方）

- 1. Spec 编写：从 ToolBench/Seal-Tools/xLAM 工具池 + Anthropic skills 仓库抽取 ~2–5k 个 skill，用强模型（Claude/GPT）按五要素模板生成 spec，关键子集人工校对。SKILL.md 格式作为种子。
- 2. 讨论性语料合成（MSM 的关键：不是 spec 原文堆砌，而是"讨论 spec 的文档"）：多体裁改写——教程、FAQ、两个工程师的争论、代码评审对话、事后复盘（postmortem）、对比评测博客、错误案例分析。每个 spec 点位 ≥10 种表述（Physics 3.1 的多样化改写要求）。
- 3. 判例库：用现有模型在 ToolScan 七类错误 taxonomy 上批量采集真实失败轨迹，配归因分析文档。
- 4. 规模：对标 MSM 的 ~41M token，目标 50–200M token（7B 模型量级），与 midtraining 常规配比（混入 5–15% 通用语料防遗忘）。

3.3 训练流程



归因纪律：Stage 2 对所有组严格一致，只动 Stage 1。SSM 语料里不含任何 Stage 2 SFT 的轨迹格式样本，避免泄漏。

3.4 对照组与 baseline

#	组	回答什么问题
B0	Base + 直接 tool SFT	主对照
B1	Base + 等量通用语料 midtraining + SFT	排除"多训了 token"的混淆
B2	Base + 等量工具轨迹 midtraining（Agentic CPT 式, arXiv:2509.13310）+ SFT	规范文本 vs 行为轨迹，数据本质之争
B3	B0 + 推理时 spec 放 context（SKILL.md / docs-in-context, arXiv:2308.00675）	故事成立的生死线：等信息量下，入权重是否胜入上下文

B4	spec 混入 SFT 阶段（DA 式）而非 midtraining	注入阶段消融（MSM 的核心对照在 skill 域复现）
B5	SMART-ER SFT (arXiv:2502.11435) / Agent-FLAN 负样本式	对比已有"教边界"方法
A1-A5	五要素逐项消融（去掉 S1...S5 之一）	哪个要素贡献最大；预期 S3 主导 selection、S5 主导 execution
A6	SSM + B3 叠加	权重内 spec 与上下文 spec 是否互补

4. 研究问题与实验设计

RQ1：SSM 是否提升 skill selection？

维度	设计
评测	MetaTool（重点报"相似工具区分"子任务）、BFCL Relevance/Irrelevance、When2Call（调用/澄清/拒绝三分）、ACEBench-Special
指标	selection acc、irrelevance 检出率、tool-call 触发率（对照 SMART 的 ">30% 多余调用"基线）、澄清率
预期	SSM 在相似工具区分与 irrelevance 上显著超 B0/B1；触发率下降而任务成功率不降

RQ2：提升是否不只是 selection，而是"用得更好"？

维度	设计
评测	T-Eval 分维度（重点 review/plan 维度）、BFCL v3 多轮、 τ^2 -bench（policy compliance）、Agent-H（幻觉）
错误分析	用 ToolScan 七类错误 taxonomy 做错误分布对比：SSM 应选择性降低参数幻觉、非法调用、错误恢复失败（S4/S5 的直接预测）
行为探针	检查模型是否在 CoT 中自发引用 spec 判据（仿 Deliberative Alignment 的引用率分析）；S5 是否引发自发验证行为（调用后检查返回值的频率）

RQ3：相比直接 tool SFT，SSM 是否更 data-efficient?

维度	设计
协议	固定评测集，Stage 2 SFT 数据取 {1/64, 1/16, 1/4, 1/1} 画 scaling 曲线（SSM vs B0/B1）；度量"达到 B0 满量性能所需 SFT 样本比例"
对标	MSM 报告的 40–60× 是安全域数字；tool 域哪怕复现 5–10× 也是强结果。tool SFT 的系统 scaling 曲线本身在文献中缺失（survey § 6.五），该实验独立成贡献
公平性	同时报告"总 token 预算对齐"的版本（SSM token + SFT token = B0 的 SFT token 上限），回应"你多训了"的质疑

RQ4：SSM 是否提升 OOD 泛化?

维度	设计
OOD 阶梯	StableToolBench G1-Tool → G1-Cat → G2-Cat → G3（unseen instruction → unseen tool → unseen category 递进）；复现 GenTool 的 Zero-to-One / Weak-to-Strong 协议
关键切分	spec-seen vs spec-unseen 工具二维拆分：(i) midtraining 见过 spec、SFT 没见过轨迹的工具——测 spec 知识直接迁移；(ii) spec 和轨迹都没见过的工具——测 spec 推理模式的迁移（核心赌注）
鲁棒性	工具描述措辞扰动（ToolTweak 式, arXiv:2510.02554）：入权重的 spec 应比 in-context 文档更抗扰动
组合泛化	NESTFUL 嵌套调用 + Seal-Tools 多工具难例：见过单 skill spec、没见过组合

5. 预期贡献

- 1. 方法：首个把 skill 适用边界/相似区分/失败模式/验证原则写成规范文本、以 midtraining 注入、再接标准 tool SFT 的训练框架（MSM 在 skill 域的扩展）。
- 2. 数据：开源 Skill Spec 语料（五要素 spec + 多体裁讨论文档 + 失败判例库）与合成 pipeline。

- 3. 实证：tool SFT 数据效率 scaling 曲线 + "spec 入权重 vs 入上下文"的首个受控对比 + 五要素归因。
- 4. 机制理解：spec 推理模式能否迁移到 spec-unseen 工具（RQ4 切分 (ii)），回答"模型学到的是知识还是元能力"。

6. 风险与缓解

风险	概率	缓解
SSM 打不过 B3（spec 放 context）	中	最先跑 B3 对照（第一个月内）。即使打平，"无需上下文开销 + 抗扰动 + 数据效率"仍可立论；若大幅落后则转向 A6 叠加故事
被抢发（MSM 后显然的扩展；skill 内化赛道 2026.4-5 三连发）	中高	3 个月内 arXiv 占坑：先放 RQ1+RQ3 的 8B 单模型结果
midtraining 损伤通用能力	低	通用语料回放 5-15%；MMLU/GSM8K/ HumanEval 监控
spec 合成质量不可控	中	关键子集人工校对；用 spec 一致性自动检查（LLM-as-judge 互评）；判例库锚定真实失败
算力	—	主实验 8B 量级：midtraining 50-200M token $\approx$ 单节点数天；消融在 1.5-3B 上先跑

7. 时间线（6 个月）

月	里程碑
M1	工具池与 spec 模板定稿；合成 pipeline v1；跑通 B0 vs B3 生死线实验（小模型）
M2	SSM 语料全量合成（50M token 起步）；8B 主线 Stage1+Stage2 第一轮
M3	RQ1 + RQ3 完整结果；arXiv preprint 占坑
M4	RQ2 错误分布 + 行为探针；RQ4 OOD 阶梯
M5	五要素消融（A1-A5）、A6 叠加、B2/B4/B5 全 baseline 补齐

8. 一句话定位

Model Spec Midtraining 证明了"先懂规范、再学行为"能以 40–60× 的数据效率塑造对齐泛化；Skill Spec Midtraining 把同一原理带到 agent 的工具世界：先懂"为什么与何时"，再学"怎么调"，让 skill selection 与 execution 在分布外依然站得住。

关键参考：MSM (alignment.anthropic.com/2026/msm) | Deliberative Alignment (2412.16339) | SMART (2502.11435) | Agent-FLAN (2403.12881) | GenTool (2502.18990) | Agentic CPT (2509.13310) | Midtraining Bridging (2510.14865) | Physics of LM 3.1 (2309.14316) | 完整文献见 [survey.html](#)