

Skill Spec Midtraining — 全链路 Build 状态报告

2026-06-12 • `/raid/longhorn/yuhao/skill-midtrain` • 合成模型 deepseek/deepseek-v4-pro (OpenRouter) • 训练基座 Qwen/Qwen3.5-4B-Base

结论：用户要求的"全链路 code 准备 + prompt 调试"已全部完成。下载→解析→Spec 生成→文档合成→质量闸→打包→训练，每一段都用真实数据/真实 API/真实 GPU 跑通；两套核心 prompt 经两轮实测迭代后验收（spec v1、docs v2）。API 总开销约 \$0.16。

16,983

统一入库 skills

12,907

SKILL.md +

4,076 API 工具

129

下载仓库

(4.3G)

curated +

GitHub 发现 + 网站收割

0/20

v2 文档 S 码残留

v1 基线 19/20

exit 0

4B 训练冒烟

4 步 • H200 单卡 • loss≈2.1

1. 流水线各段状态

阶段	实现	实测结果	状态
0a 下载源	<code>src/collect/download.py</code> + <code>configs/sources.yaml</code>	129 repos (anthropics/skills、superpowers、GitHub 6 组发现查询、skillsmp/marketplace 网站收割) + Seal-Tools；xLAM gated 已留开关	已跑完
0b 解析入库	<code>src/collect/parse_skills.py</code>	16,983 skills (去重后)，两种 kind 统一 schema	已跑完
A Spec 生成	<code>src/synth/gen_specs.py</code> + <code>prompts/skill2spec_v1.md</code>	试点 5/5 通过校验（五要素、TF-IDF 近邻注入 S3 对	prompt 验收

		比)；markdown 渲染人审通过	
B 文档合成	<code>src/synth/gen_docs.py + doc_ideas_v2 / doc_writer_v2 / doc_genres.yaml</code> (16 体裁)	v2 试点 20/20 成功、17.1k 词；零术语回声（详见 § 2）	prompt 验收
B' 质量闸	<code>src/synth/quality.py</code>	防泄漏正则（SFT 轨迹格式/标签残留）+ 长度/重复 + 6-gram LSH 近重去重；v2 通过 20/20	已验证
C1 语料打包	<code>src/train/build_corpus.py</code>	Qwen3.5-4B tokenizer、EOS 分隔、uint32 memmap；v2 试点 23.3k tokens → 21+1 blocks	已跑通
C2 Midtrain	<code>src/train/train_midtrain.py + configs/train_qwen3p5_4b.yaml</code>	单卡 smoke 4 步 exit 0（loss 1.9→2.5 波动属 16 块小样本正常）；8 卡 torchrun 配置就绪（512k tok/step）	smoke 通过

一键脚本：`scripts/01_download.sh ... 05_train.sh`（`NGPU=8 scripts/05_train.sh` 即正式跑）。

2. Prompt 调试两轮迭代（核心交付）

Round 1 • skill→Spec（v1 验收）

- 修 `parse_json_block` 数组优先 bug（4/5 误判 missing elements）。
- deepseek-v4-pro 思考 token 烧 `max_tokens` → client 加 `reasoning effort=low`、截断/空回不缓存且 ×1.5 重试。重跑 5/5。
- 质量证据：pdf spec 的 S3 真实对比近邻技能给选择判据；S4 抓到 SKILL.md 真实 reportlab Unicode 警告；API 工具 spec 含 London/Ontario 歧义等带归因判例。

Round 2 · Spec→讨论文档（v1→v2，关键修复）

指标（20 篇试点）	v1	v2
正文出现 S1-S5 编号 （术语回声）	19/20	0/20
提及 "spec/guideline 文档"	20/20	2/20，且全部在 <code>formal_spec_reference: true</code> 体裁（audit report）——设计内
重代码块被拒	2/20	0/20
质量闸通过	17/20	20/20

手段：digest 去标签注入（`spec_digest(labeled=False)`）、明令禁 S 码、spec 提及按体裁条件化（formal 3 种可引用 guideline，其余 13 种必须化为作者经验/团队 lore）、prose-first。抽检文风自然（docx 表格 DXA 宽度论辩、pdfplumber vs pdf-analyzer 判据交锋）。附带修复 1/20 的 `<content>` 标签残留（`extract_tag` 容错 + 质量闸兜底规则）。完整记录见 `prompts/DEBUG_LOG.md`，审计工具 `src/synth/audit_docs.py`。

3. 正式跑放量清单（下一步，待指示）

事项	说明
Spec 全量生成	16,983 skills；按试点单价约 \$0.006/spec，全量约 \$100；可 <code>--limit/--kind</code> 分批
文档全量合成	默认 4 体裁 × 3 ideas/skill $\approx$ 12 docs/skill；按目标 token 预算定采样规模（试点约 1.2k tok/doc、\$0.0035/doc）
Replay 语料	正式 midtrain 需 <code>--replay</code> 混 ~10% 通用语料防遗忘（HF 缓存已有 fineweb-edu 可用）；纯 SSM 仅限冒烟
训练提速	Qwen3.5 混合线性注意力：装 <code>flash-linear-attention + causal-conv1d</code> （当前回退 torch 实现，能跑但慢）
评测（B0-B5）	proposal 中对照组与 Stage-2 SFT/评测桩未在本期范围；建议先跑 B3 生死线

4. 产物索引

<code>data/skills.jsonl</code>	16,983 skills (统一 schema)
<code>data/debug/specs_pilot_v1.jsonl</code>	5 spec (+ md/ 人审渲染)
<code>data/debug/docs_pilot_v2*.jsonl</code>	20 docs (clean 同 20)
<code>data/debug/corpus_v2/</code>	train.bin/val.bin/meta.json (23.3k tok)
<code>checkpoints/smoke/</code>	冒烟产物
<code>prompts/DEBUG_LOG.md</code>	两轮迭代完整记录
<code>README.md</code>	流水线总览与用法
<code>logs/api_calls.jsonl</code>	70 次调用 (159k prompt + 188k completion tokens)